

DESCRIPCIÓN DE FUENTES DE DATOS

Sistema de Transporte Masivo Urbano

Danna Camila Guerra Rincon

Facultad de Ingeniería – Ingeniería en Ciencia de Datos

Corporación Universitaria Iberoamericana

20042026: Inteligencia Artificial

Ing. Joaquín Sánchez

Junio de 2026

1. Contexto del Proyecto

El presente dataset fue diseñado para soportar el desarrollo de un modelo de aprendizaje no supervisado aplicado al sistema de transporte masivo urbano. El proyecto es continuacion de las actividades previas del curso en las que se definio una arquitectura en la nube para el sistema TrackFleet, una plataforma de seguimiento GPS de flotas. En esta etapa, el objetivo es identificar patrones de comportamiento en los viajes realizados por el sistema, sin necesidad de etiquetas previas, mediante el algoritmo K-Means.

2. Descripcion General del Dataset

El dataset contiene registros sinteticos de viajes del sistema de transporte masivo, generados con distribuciones estadisticas representativas de patrones reales de movilidad urbana. Se simularon condiciones de hora pico, demanda variable por ruta, factores climaticos y ocurrencia de incidentes.

Característica	Valor
Numero de registros	300 viajes
Numero de variables	12 columnas
Variables numericas	7
Variables categoricas	4
Variable identificador	1 (id_viaje)
Periodo simulado	Semana tipica (Lunes - Domingo)
Franjas horarias	5:00 a 22:00
Formato del archivo	CSV (dataset_transporte.csv)
Codificacion	UTF-8
Separador	Coma (,)

3. Descripcion de Variables

La siguiente tabla detalla cada variable del dataset, su tipo de dato, los valores posibles y su relevancia para el modelo de clustering:

Variable	Tipo	Rango / Valores	Descripcion
id_viaje	String	V0001 - V0300	Identificador unico de cada viaje
ruta	Categorica	5 rutas (R1-R5)	Ruta del sistema (Centro, Norte, Sur, Oriental, Occidenta)
estacion_origen	Categorica	4 por ruta	Estacion de inicio del viaje
estacion_destino	Categorica	4 por ruta	Estacion de llegada del viaje
dia_semana	Categorica	Lunes - Domingo	Dia de la semana del viaje
hora_salida	Entero	5 - 22	Hora de salida (formato 24h, hora pico: 7-8 y 17-18)
pasajeros	Entero	92 - 920	Numero de pasajeros en el viaje
distancia_km	Decimal	3.8 - 21.7 km	Distancia recorrida en el viaje (fraccion de la ruta total)
tiempo_viaje_min	Decimal	7 - 42 min	Duracion del viaje en minutos
incidente	Binario	0 o 1	Indicador de incidente durante el viaje (1 = incidente)
temperatura_c	Decimal	13 - 22 grados C	Temperatura ambiente al momento del viaje

4. Variables Utilizadas en el Modelo

Para el entrenamiento del modelo K-Means se seleccionaron las seis (6) variables numericas que mejor capturan el comportamiento temporal, la demanda y las condiciones del viaje:

Variable	Justificacion de inclusion
hora_salida	Captura patrones temporales: hora pico vs. hora valle
pasajeros	Variable central de demanda del sistema
distancia_km	Refleja el alcance del viaje y el tipo de conexion entre estaciones
tiempo_viaje_min	Correlacionada con distancia y condiciones del trafico
temperatura_c	Factor externo que puede influir en la demanda y operacion
lluvia_mm	Factor climatico que afecta la afluencia de pasajeros

Las variables categoricas (ruta, estacion, dia_semana) y el identificador (id_viaje) fueron

excluidas del entrenamiento ya que K-Means opera sobre distancias euclidianas en espacio continuo. Sin embargo, estas variables se usaron en el analisis posterior de los clusters formados.

5. Estadísticas Descriptivas

Variable	Min	Max	Media	Desv. Estandar	Mediana
hora_salida	5	22	13.39	5.27	14.0
pasajeros	92	920	437.18	207.50	416.5
distancia_km	3.80	21.70	9.38	4.82	8.9
tiempo_viaje_min	7.0	41.9	18.7	8.1	17.2
temperatura_c	13.0	22.0	17.55	2.69	17.5
lluvia_mm	0.0	14.7	7.22	4.24	7.3

6. Preprocesamiento Aplicado

Previo al entrenamiento se aplico normalizacion con StandardScaler de scikit-learn, que transforma cada variable para tener media 0 y desviacion estandar 1. Este paso es obligatorio para K-Means porque el algoritmo calcula distancias euclidianas: sin normalizacion, variables con mayor magnitud numerica (como el numero de pasajeros, en el orden de los cientos) dominarian por completo el calculo de distancias sobre variables como temperatura (en el orden de las decenas), generando clusters sesgados que no reflejan la estructura real de los datos.

7. Origen de los Datos

El dataset fue generado sinteticamente mediante el script Python `gen_dataset.py`, utilizando distribuciones estadisticas calibradas con base en patrones reales de sistemas de transporte masivo como TransMilenio (Bogota). Las distribuciones de demanda por hora replican el patron bimodal caracteristico de los sistemas de transporte urbano (pico matutino 7-8h y vespertino 17-18h). Los valores de temperatura y precipitacion corresponden al rango climatico tipico de ciudades andinas colombianas.