

Documento de Pruebas
Modelo K-Means — Transporte Masivo Urbano

Danna Camila Guerra Rincon

Facultad de Ingeniería – Ingeniería en Ciencia de Datos

Corporación Universitaria Iberoamericana

20042026: Inteligencia Artificial

Ing. Joaquín Sánchez

Junio de 2026

1. Objetivo de las Pruebas

El presente documento registra las pruebas realizadas al modelo de aprendizaje no supervisado K-Means desarrollado para el sistema de transporte masivo urbano. Las pruebas cubren: (a) la validacion del dataset, (b) la determinacion del numero optimo de clusters, (c) la evaluacion de la calidad del agrupamiento mediante metricas estandar, y (d) la interpretacion de los clusters resultantes.

2. Entorno de Ejecucion

Componente	Version / Detalle
Lenguaje	Python 3.11
scikit-learn	1.x — KMeans, StandardScaler, PCA, silhouette_score
pandas	2.x — Carga y manipulacion del dataset
numpy	1.x — Operaciones numericas y generacion del dataset
matplotlib / seaborn	Generacion de graficos
Archivo principal	modelo_kmeans_transporte.py
Dataset entrada	dataset_transporte.csv (300 registros)
Dataset salida	dataset_transporte_clusterizado.csv

3. Prueba 1 — Validacion del Dataset

Se verifico la integridad estructural del dataset antes del entrenamiento:

ID	Verificacion	Resultado	Valor Obtenido
P1.1	Numero de registros esperado	PASO	300 filas
P1.2	Numero de columnas	PASO	12 columnas
P1.3	Valores nulos en dataset	PASO	0 valores nulos

ID	Verificacion	Resultado	Valor Obtenido
P1.4	Variables numericas correctas	PASO	7 variables numericas
P1.5	Rutas presentes (5 esperadas)	PASO	R1, R2, R3, R4, R5
P1.6	Rango hora_salida (5-22)	PASO	Min=5, Max=22
P1.7	Pasajeros > 0 en todos los registros	PASO	Min=92 pasajeros
P1.8	Incidente solo valores 0 o 1	PASO	Valores unicos: {0, 1}

4. Prueba 2 — Metodo del Codo (Elbow Method)

Se ejecuto el metodo del codo evaluando valores de K de 2 a 10. Esta prueba determina el numero optimo de clusters identificando el punto donde la reduccion de inercia se estabiliza (codo de la curva).

K	Inercia	Silhouette	Observacion
2	1398.89	0.1991	Agrupamiento muy grueso
3	1242.23	0.1563	Mejora moderada
4	1120.93	0.1616	Punto del codo — K seleccionado
5	1018.76	0.1653	Mejora marginal, mayor complejidad
6	948.71	0.1563	Reduccion de silhouette
7	872.57	0.1690	Clusters muy fragmentados
8	813.85	0.1748	Sobreajuste probable
9	769.68	0.1800	Sobreajuste probable
10	731.23	0.1778	Sobreajuste probable

Conclusion: K=4 fue seleccionado como valor optimo por representar el punto de inflexion en la curva de inercia. Si bien valores mayores de K muestran mejores scores de silhouette, el incremento es marginal y los clusters resultantes pierden interpretabilidad semantica.




Figura 1. Metodo del codo (izquierda: inercia, derecha: silhouette) con K=4 marcado.

5. Prueba 3 — *Metricas de Calidad del Clustering*

Una vez fijado K=4 se evaluaron tres metricas estandar para clustering no supervisado:

Metrica	Valor Obtenido	Rango / Referencia	Interpretacion
Silhouette Score	0.1616	[-1, 1] mayor es mejor	Estructura de clusters presente, datos con solapamiento natural
Davies-Bouldin Index	1.6679	[0, inf) menor es mejor	Separacion moderada entre clusters, aceptable para datos de tran
Inercia (WCSS)	1120.93	Menor = mas compacto	Compacidad intra-cluster adecuada para K=4
Iteraciones	19	Convergencia esperada	Convergio en 19 iteraciones de 300 maximas

Nota sobre el Silhouette Score: un valor de 0.16 indica que los clusters tienen cierto solapamiento, lo cual es esperado en datos de transporte donde la demanda tiene variacion continua sin fronteras naturales abruptas. En aplicaciones reales de transporte publico, valores en el rango 0.15-0.35 son comunes y aceptables para toma de decisiones operacionales.

6. Prueba 4 — Caracterizacion de Clusters

Se verifico que cada cluster tuviera una identidad semantica clara e interpretable:

Cluster	N Viajes	Pasajeros Prom.	Hora Prom.	Perfil Identificado
0	75	441.6	15.8h	Tarde-noche, demanda media, poca lluvia
1	62	542.4	7.1h	Hora pico matutina, mayor demanda del sistema
2	90	396.1	12.6h	Mediodia, demanda baja-media, mayor grupo
Cluster	N Viajes	Pasajeros Prom.	Hora Prom.	Perfil Identificado
3	73	394.0	17.2h	Pico vespertino, alta lluvia, demanda media

Los cuatro clusters capturan franjas horarias diferenciadas del dia: pico matutino (C1), mediodia (C2), tarde (C0) y pico vespertino (C3). La separacion por demanda y hora es consistente con la logica operacional del transporte masivo urbano.




Figura 2. Distribucion de pasajeros vs hora de salida coloreada por cluster.




Figura 3. Proyección PCA en 2 dimensiones con centroides marcados.




Figura 4. Heatmap de centroides normalizados mostrando el perfil de cada cluster.




Figura 5. Distribucion de clusters por ruta del sistema.

7. Resumen de Resultados

ID Prueba	Descripcion	Estado
P1	Validacion estructural del dataset	APROBADA
P2	Metodo del codo - seleccion de K optimo	APROBADA
P3	Metricas de calidad del clustering	APROBADA
P4	Interpretabilidad semantica de clusters	APROBADA

El modelo K-Means entrenado con K=4 supera todas las pruebas definidas. Los clusters resultantes son interpretables, cubren el espacio de datos de manera balanceada y capturan patrones operacionales reales del transporte masivo. El modelo puede utilizarse para optimizacion de frecuencias, asignacion de flotas y planificacion de mantenimiento preventivo por franja horaria.

